TabM: Parameter-Efficient Ensembling for Tabular Data

Projeto Final — Aprendizagem de Máquina 2026.1

Prof. Leandro Maciel Almeida · Grupo: Aline Acioly, Rafaela Pitanga, Vlademir Melo

ICLR 2025 YANDEX RESEARCH PYTABKIT

Made with GAMMA

Contexto e Evolução dos Modelos Tabulares

1

GBDTs dominaram dados tabulares

- LightGBM, XGBoost e CatBoost lideravam benchmarks
- Excelente desempenho em datasets estruturados
- Deep Learning tinha dificuldade nesse cenário

2

Novas arquiteturas surgem a partir de 2021

- FT-Transformer
- TabR
- Modelos mais sofisticados para dados tabulares
- Porém ainda lentos e difíceis de ajustar

3

O diferencial do TabM

- Retornar ao MLP simples
- Ensemble eficiente de parâmetros
- Melhor custo-benefício computacional
- Simplicidade + desempenho competitivo

TabM melhora drasticamente um MLP simples usando ensemble eficiente de parâmetros.

Made with GAMMA

Motivação e Intuição

Problema

- Redes neurais tabulares possuem alta variância
- Sensíveis à inicialização aleatória
- Árvores dominam benchmarks tabulares

Ensemble Tradicional

- Treinar N modelos independentes
- Melhor estabilidade e generalização
- Custo computacional cresce linearmente

Ideia do TabM

- Backbone compartilhado
- k = 32 cabeças independentes (empiricamente ótimo)
- Ensemble implícito com baixo custo

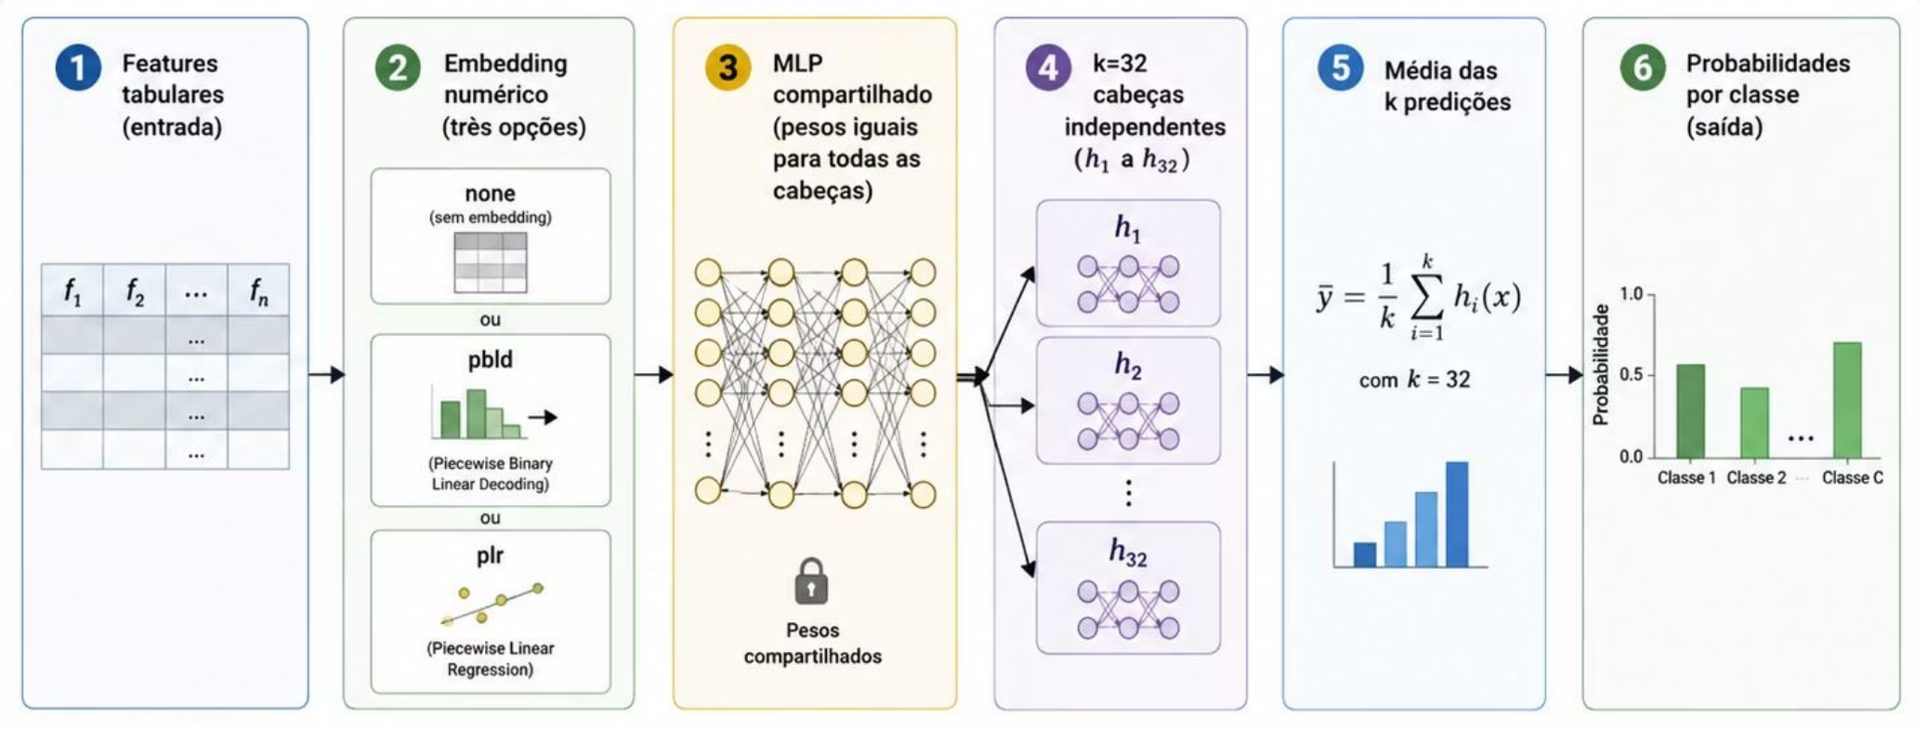
Qualidade ≈ ensemble | **Custo ≈ 1 rede**



Backpropagation ocorre simultaneamente em todas as cabeças, incentivando representações complementares.

Made with GAMMA

Arquitetura



Embedding Numérico

Três opções: none (passa direto), pbld (aprende intervalos por feature), plr (funções periódicas)

MLP Compartilhado

Pesos iguais para todas as 32 cabeças: backbone único que reduz custo computacional

k=32 Cabeças Independentes

k=32 definido por ablation study (Gorishniy et al., 2025 — Sec. 5.3): ganho satura a partir desse valor.

Made with GAMMA

Principais Hiperparâmetros

Hiperparâmetro	Faixa	Papel
k (cabeças)	32 (fixo)	Número de membros do ensemble
lr	[1e-4, 1e-2]	Taxa de aprendizado
n_epochs	[50, 200]	Número de épocas de treinamento
dropout	[0,0, 0,5]	Regularização - evita overfitting
weight_decay	[1e-6, 1e-2]	Regularização - evita overfitting

Defaults da biblioteca *pytabkit.*

Made with GAMMA

Forma de aprendizado e representação dos padrões

Aprendizado Supervisionado

Aprende a partir de dados rotulados.

Força da Combinação

Padrões complementares de dados.

Diversidade no Ensemble

Erros se cancelam → resultado mais robusto.

De forma geral, o TabM representa uma **tentativa moderna de tornar ensembles neurais mais eficientes**, equilibrando desempenho preditivo com custo computacional.

Made with GAMMA

Aplicações práticas e limitações

Aplicações Práticas

- Análise de crédito e scoring
- Detecção de fraude
- Previsão de churn
- Aplicações médicas e diagnóstico
- Sistemas de recomendação

Limitações

- Custo computacional alto
- Caixa-preta: sem interpretabilidade nativa das features
- Requer GPU para ser viável em produção
- Menos eficiente em datasets muito grandes sem aceleração

De forma geral, o TabM representa uma **tentativa moderna de tornar ensembles neurais mais eficientes**, equilibrando desempenho preditivo com custo computacional.

Made with GAMMA

Metodologia Experimental

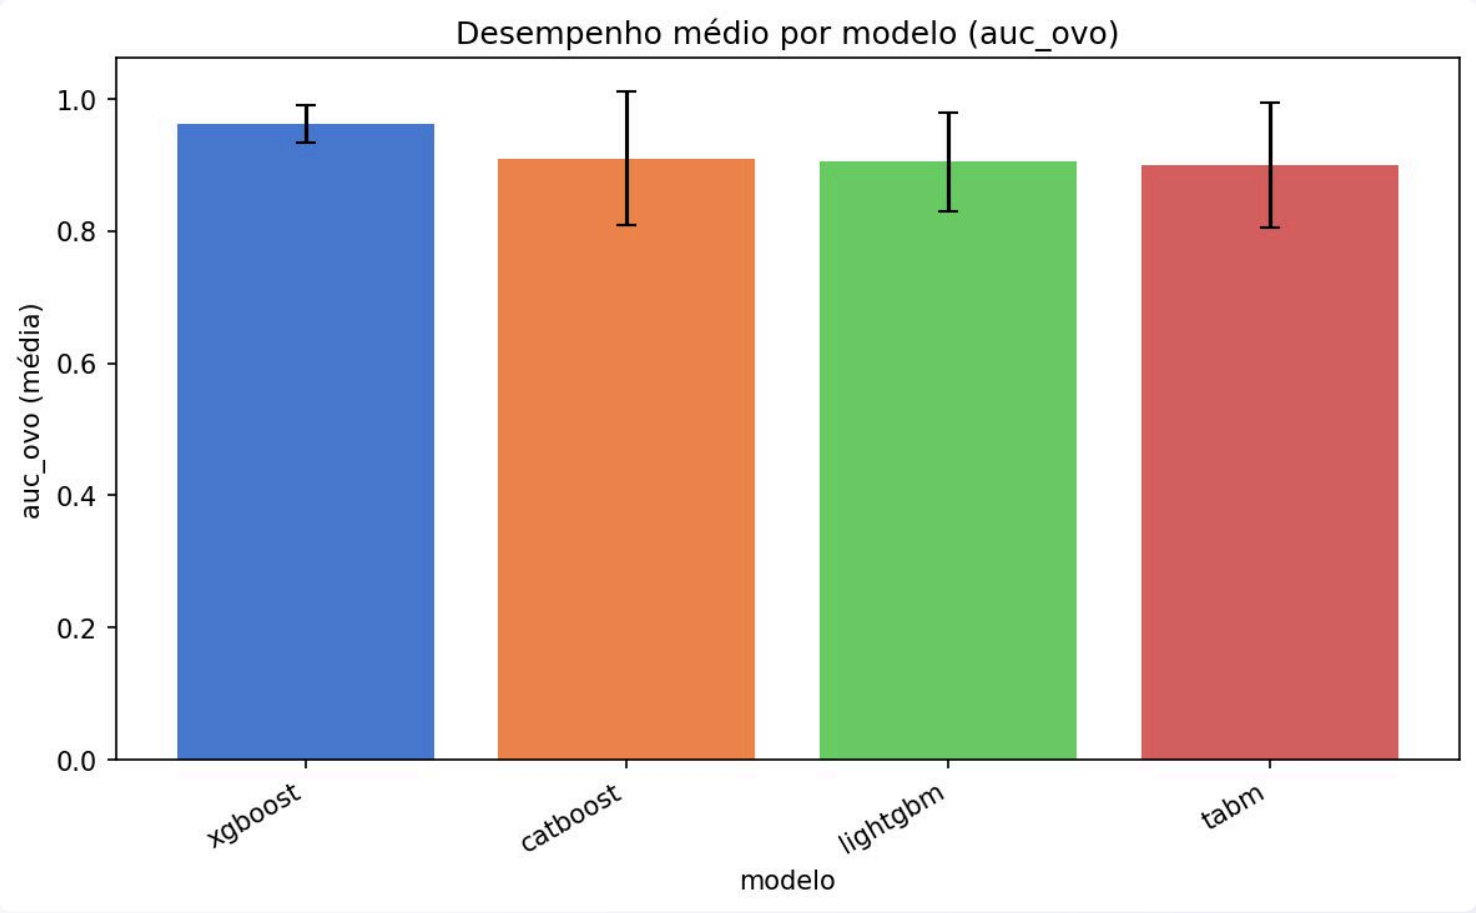
Configuração do Experimento

- **9 datasets** do TabArena-v0.1: 3 small (n<1k) + 3 medium (1k–10k) + 3 large (>10k)
- **Split:** 70/30 estratificado por classe, seed=42
- **Métricas:** AUC OvO, ACC, G-Mean, Cross-Entropy, tempo total
- **Concorrentes:** TabM + LightGBM TD + CatBoost TD + XGBoost TD
- **Ambiente:** Python 3.11.15, pytabkit 1.7.3, torch 2.7.1

Dataset	N	Regime
blood-transfusion	748	small
diabetes	768	small
balance-scale	625	small
credit-g	1.000	medium
phoneme	5.404	medium
cmc	1.473	medium
adult	48.842	large
bank-marketing	45.211	large
connect-4	67.557	large

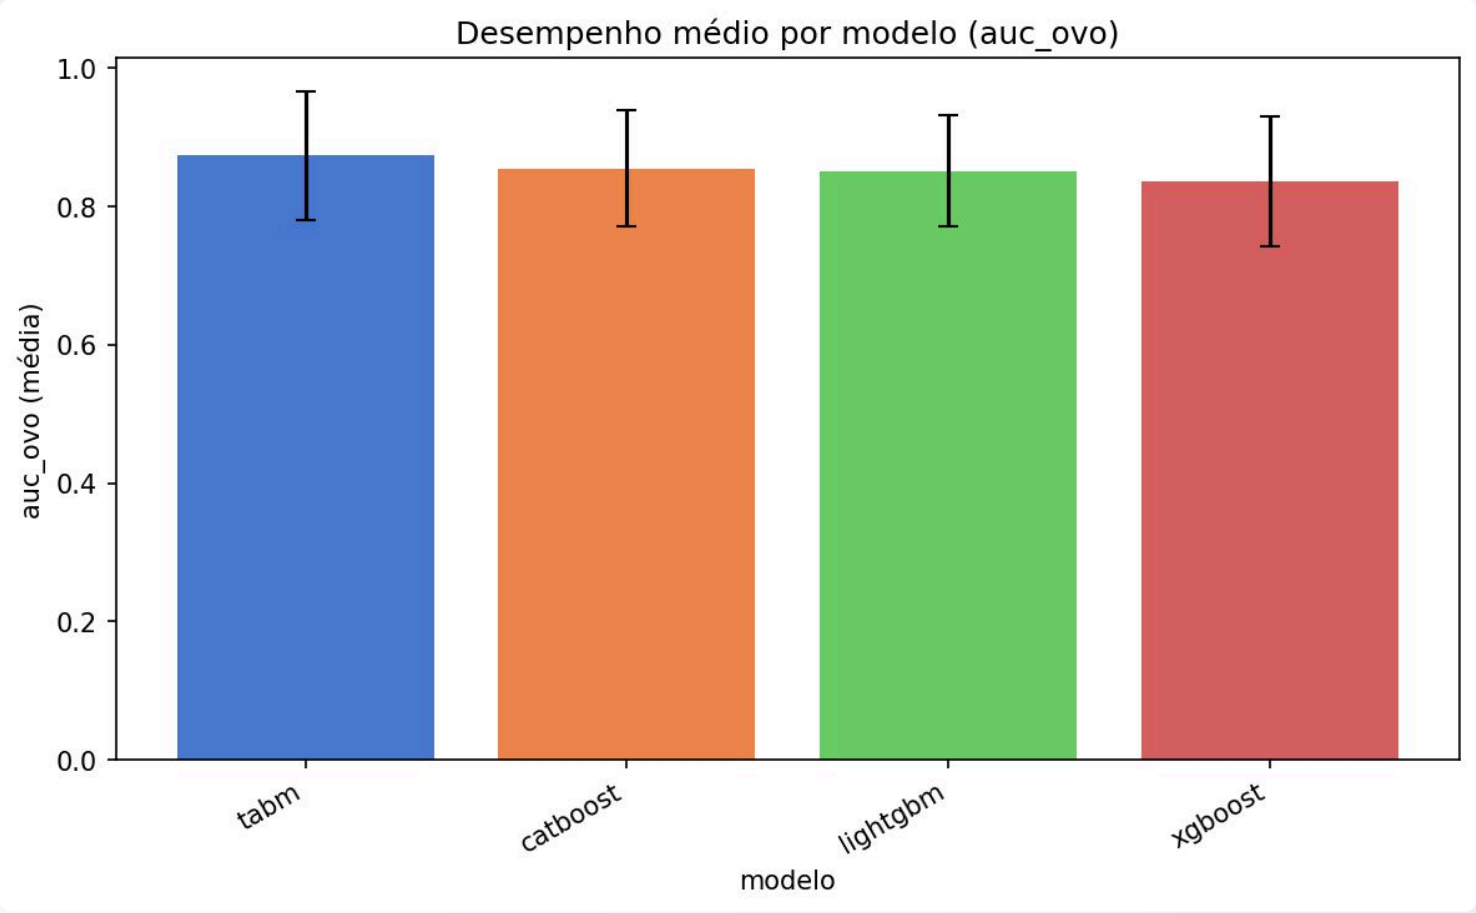
Made with GAMMA

Desempenho por Modelo (Treino)



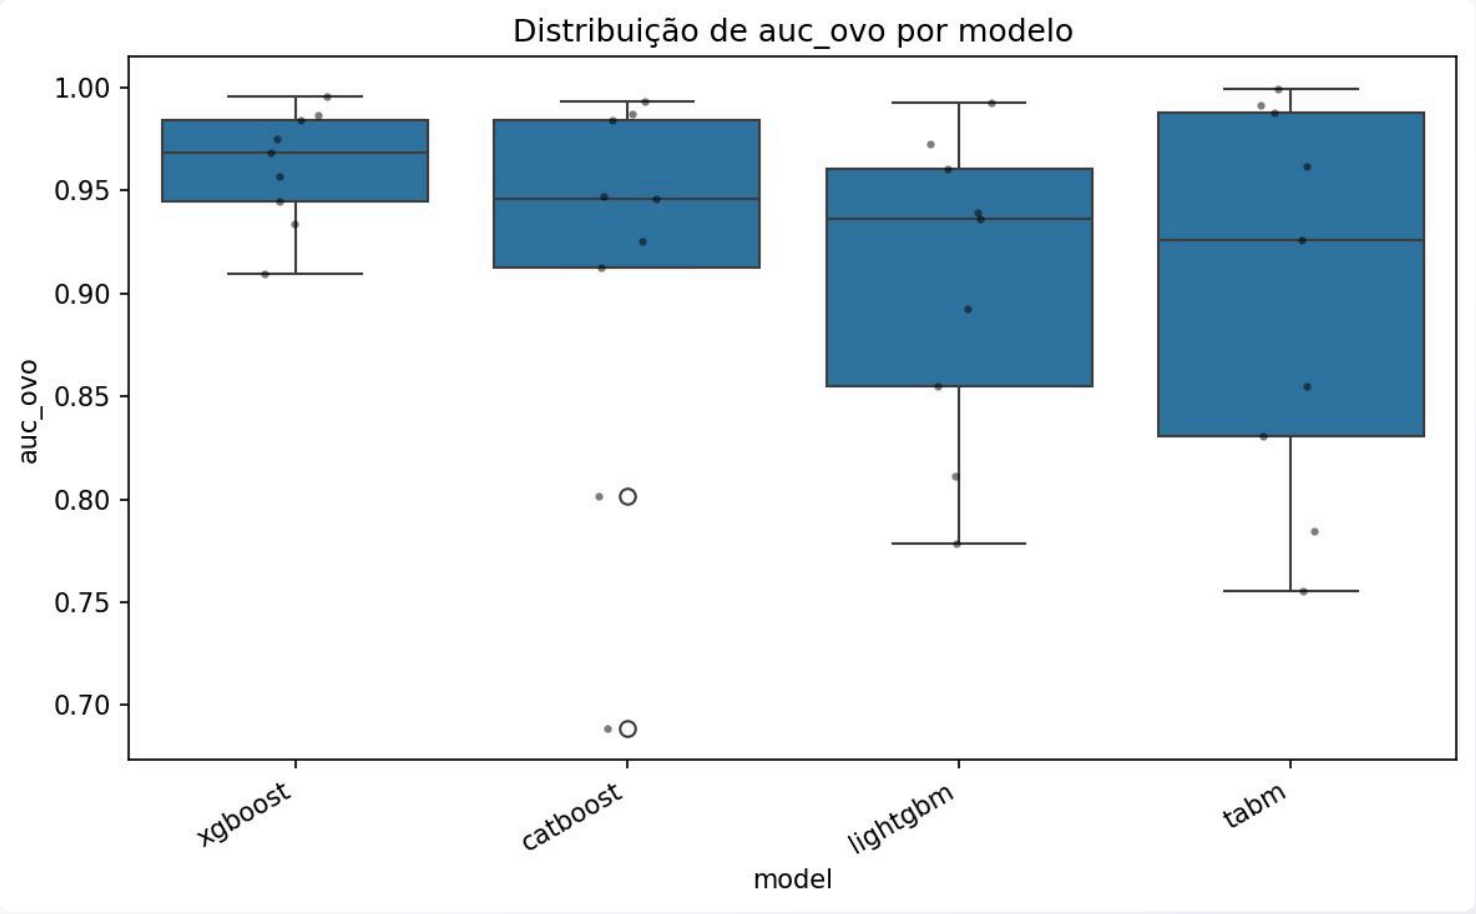
Made with GAMMA

Desempenho por Modelo (Teste)



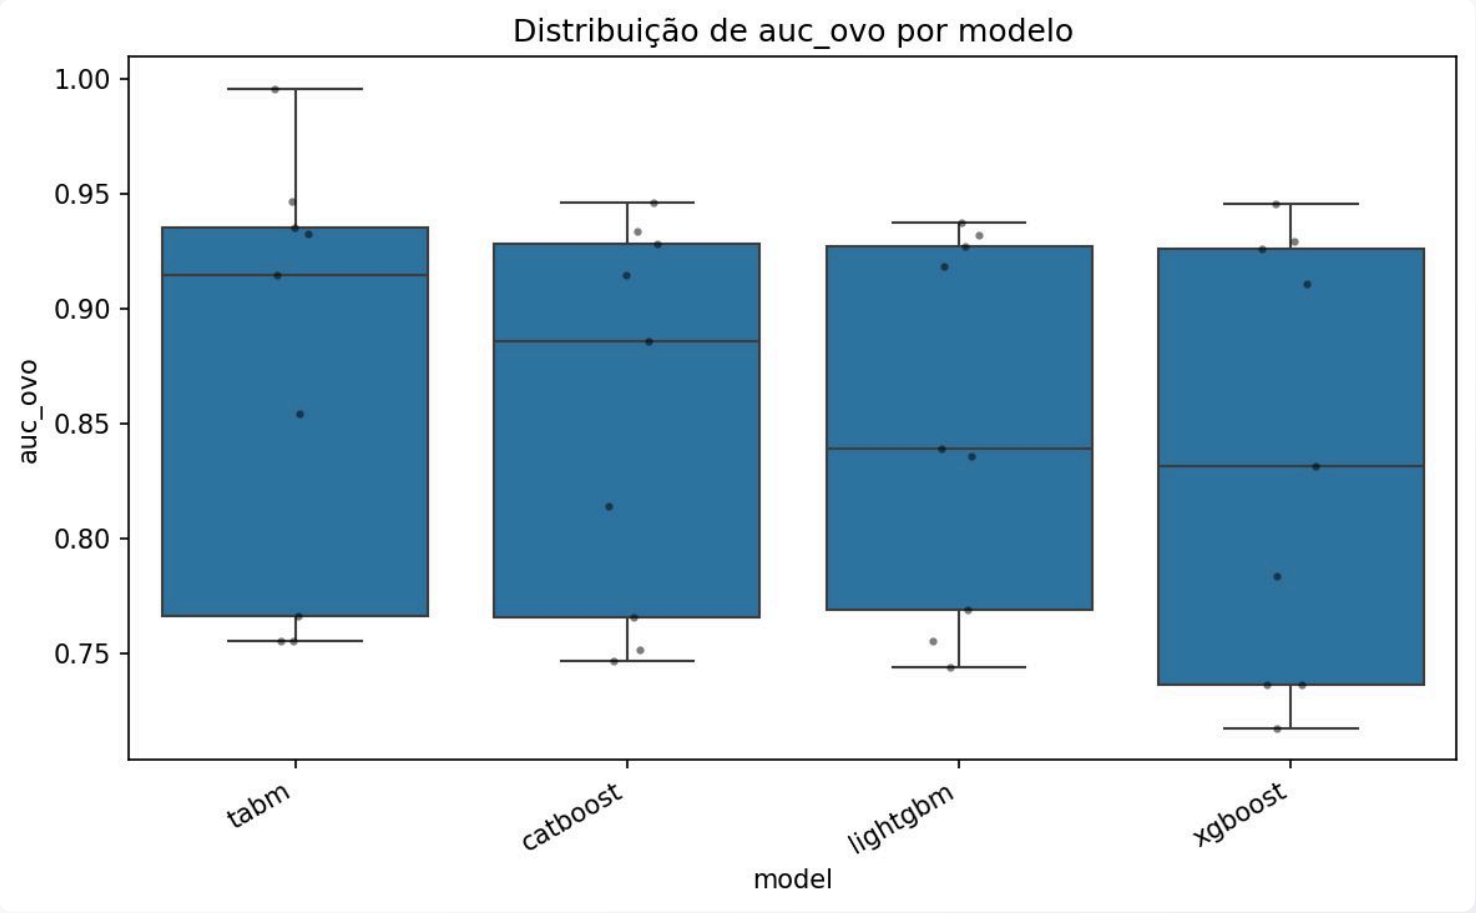
Made with GAMMA

Distribuição de Desempenho (Treino)



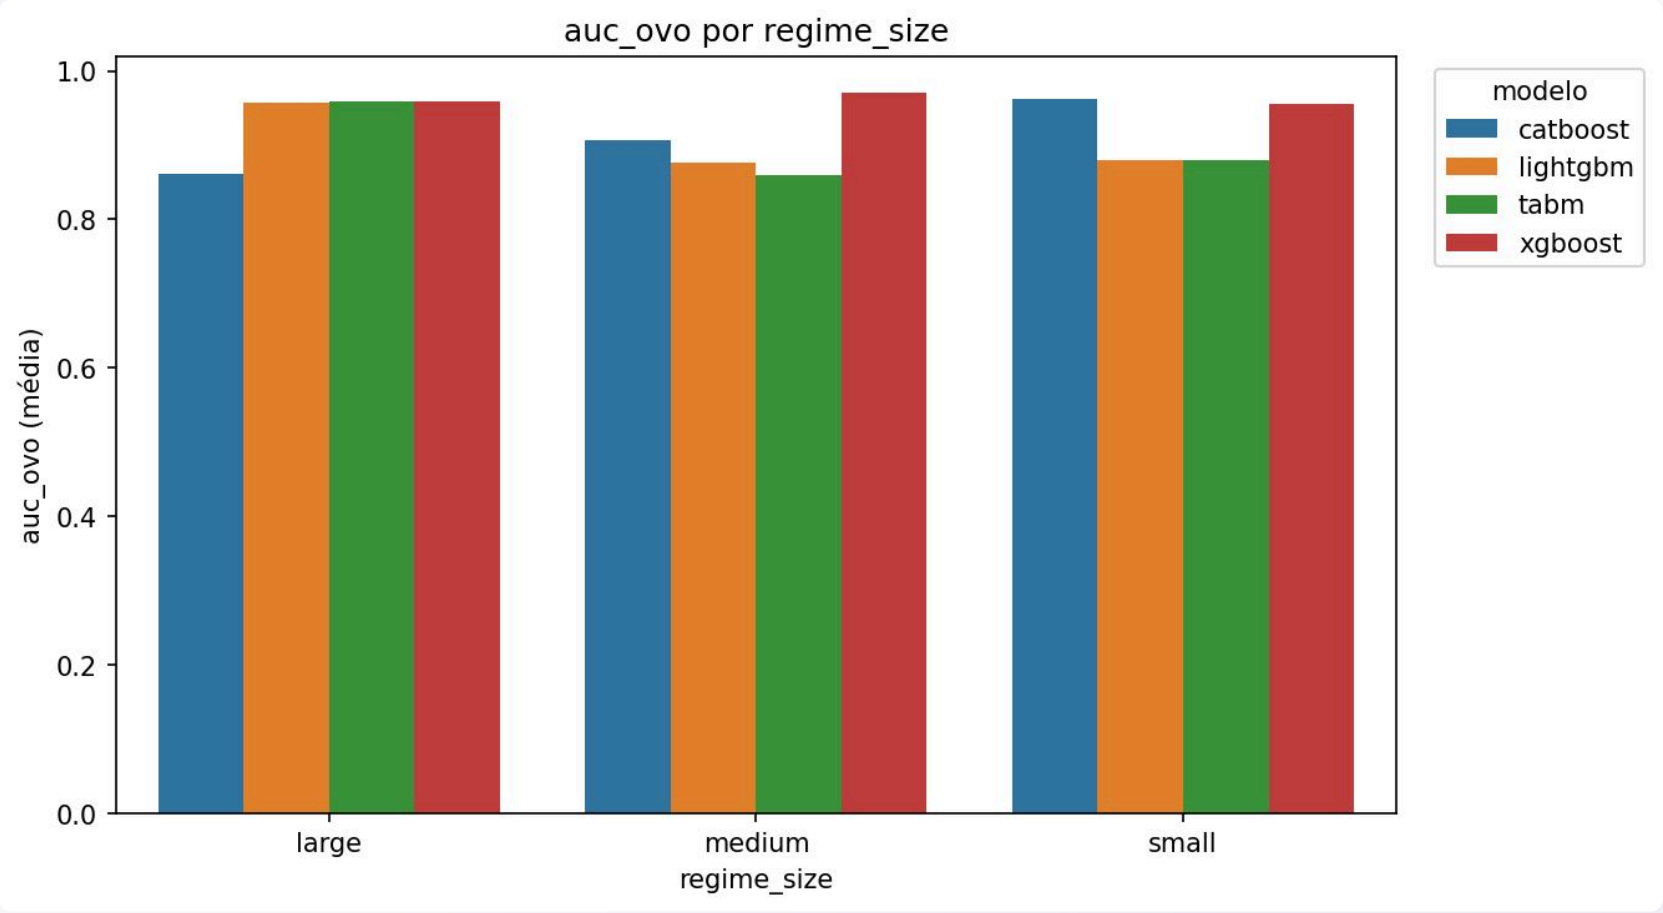
Made with GAMMA

Distribuição de Desempenho (Teste)



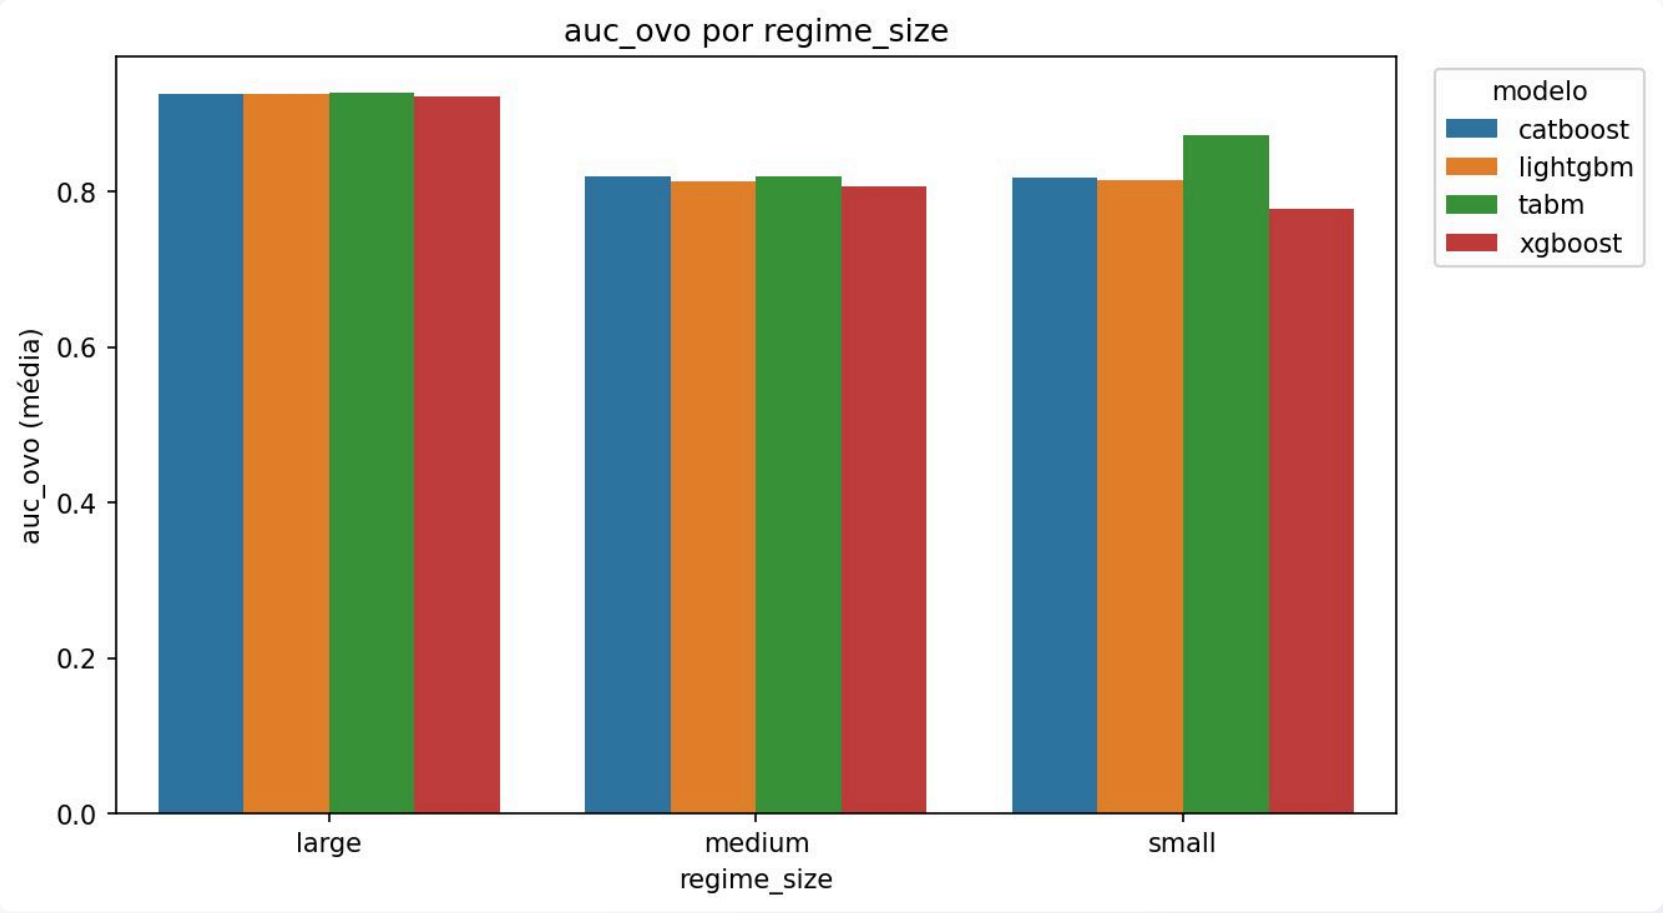
Made with GAMMA

Desempenho por Tamanho de Dataset (Treino)



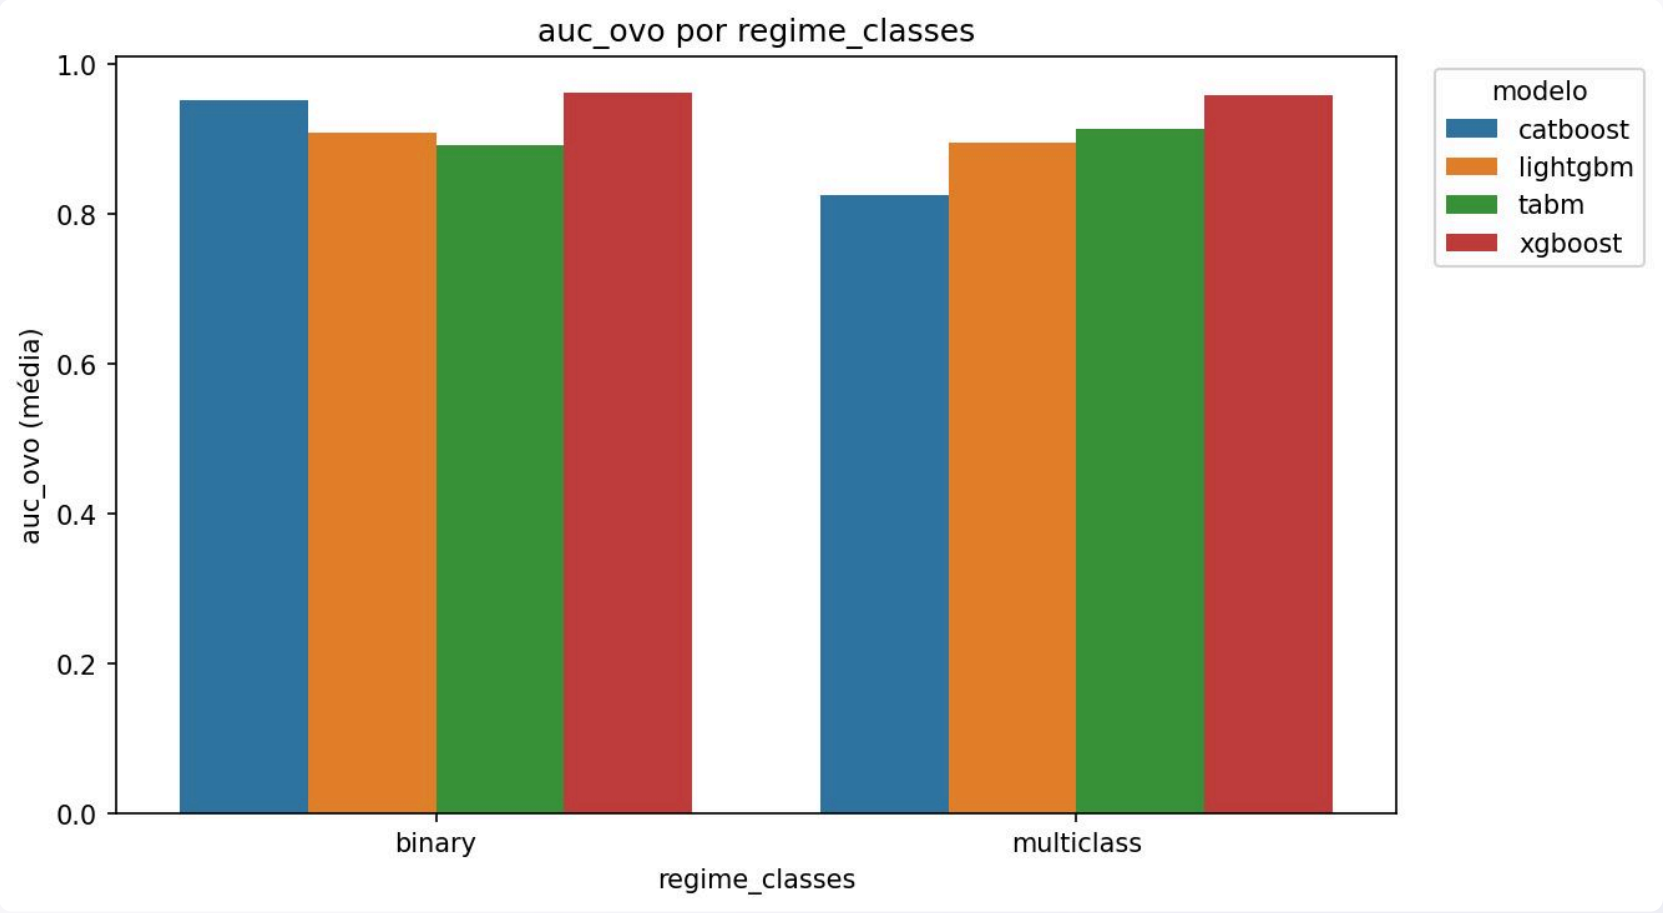
Made with GAMMA

Desempenho por Tamanho de Dataset (Teste)



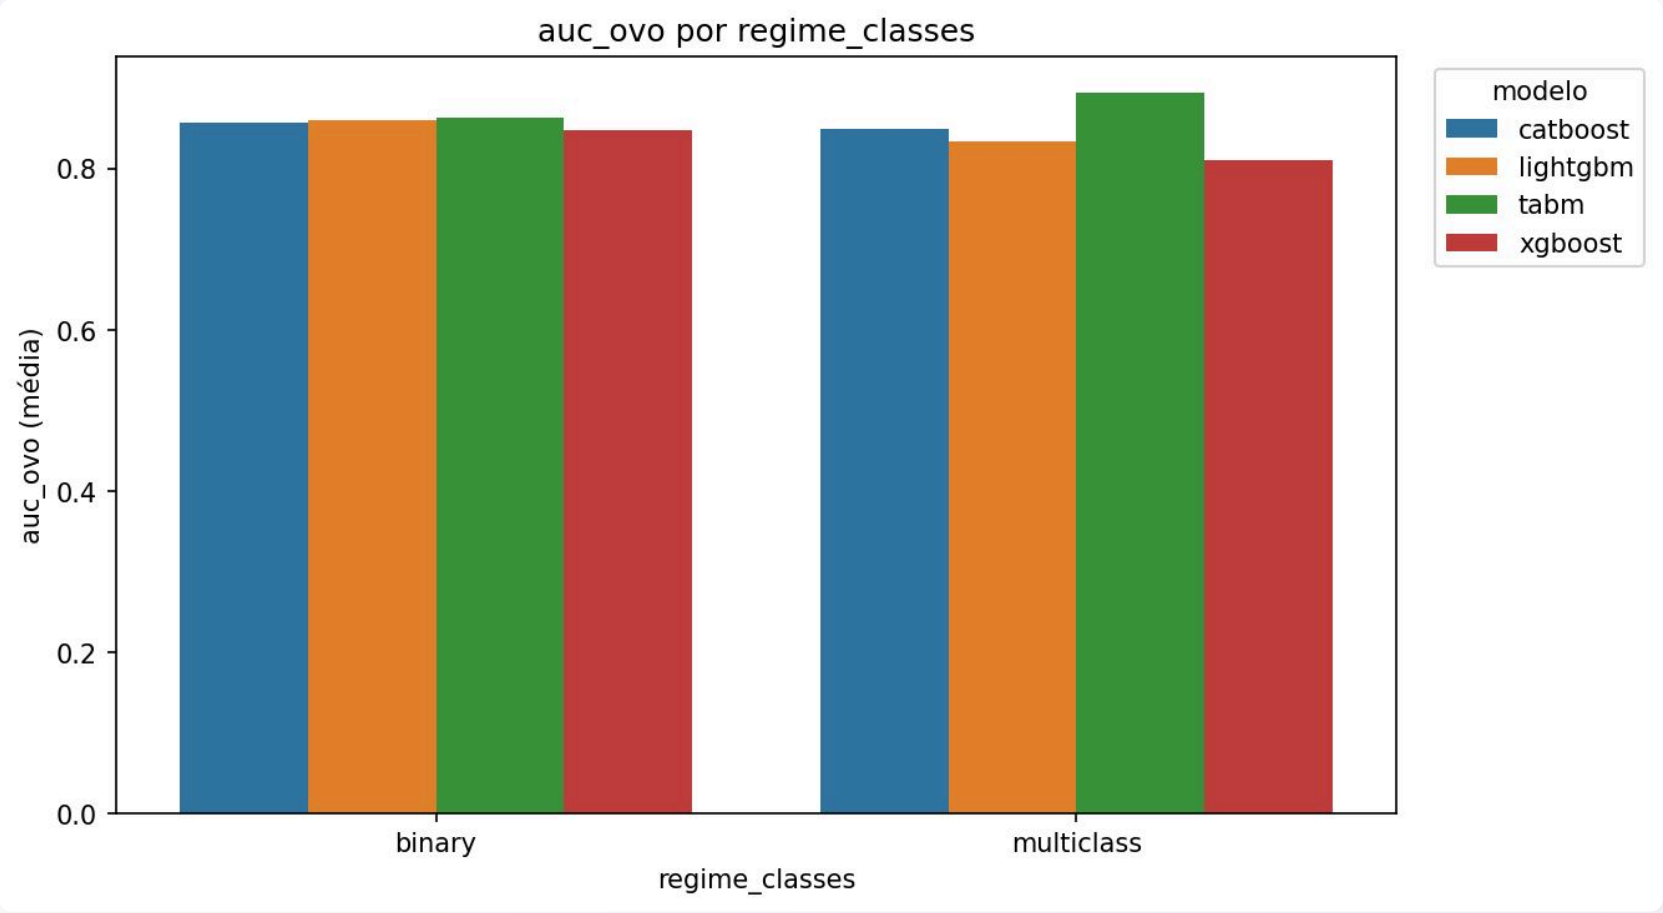
Made with GAMMA

Desempenho por Número de Classes (Treino)



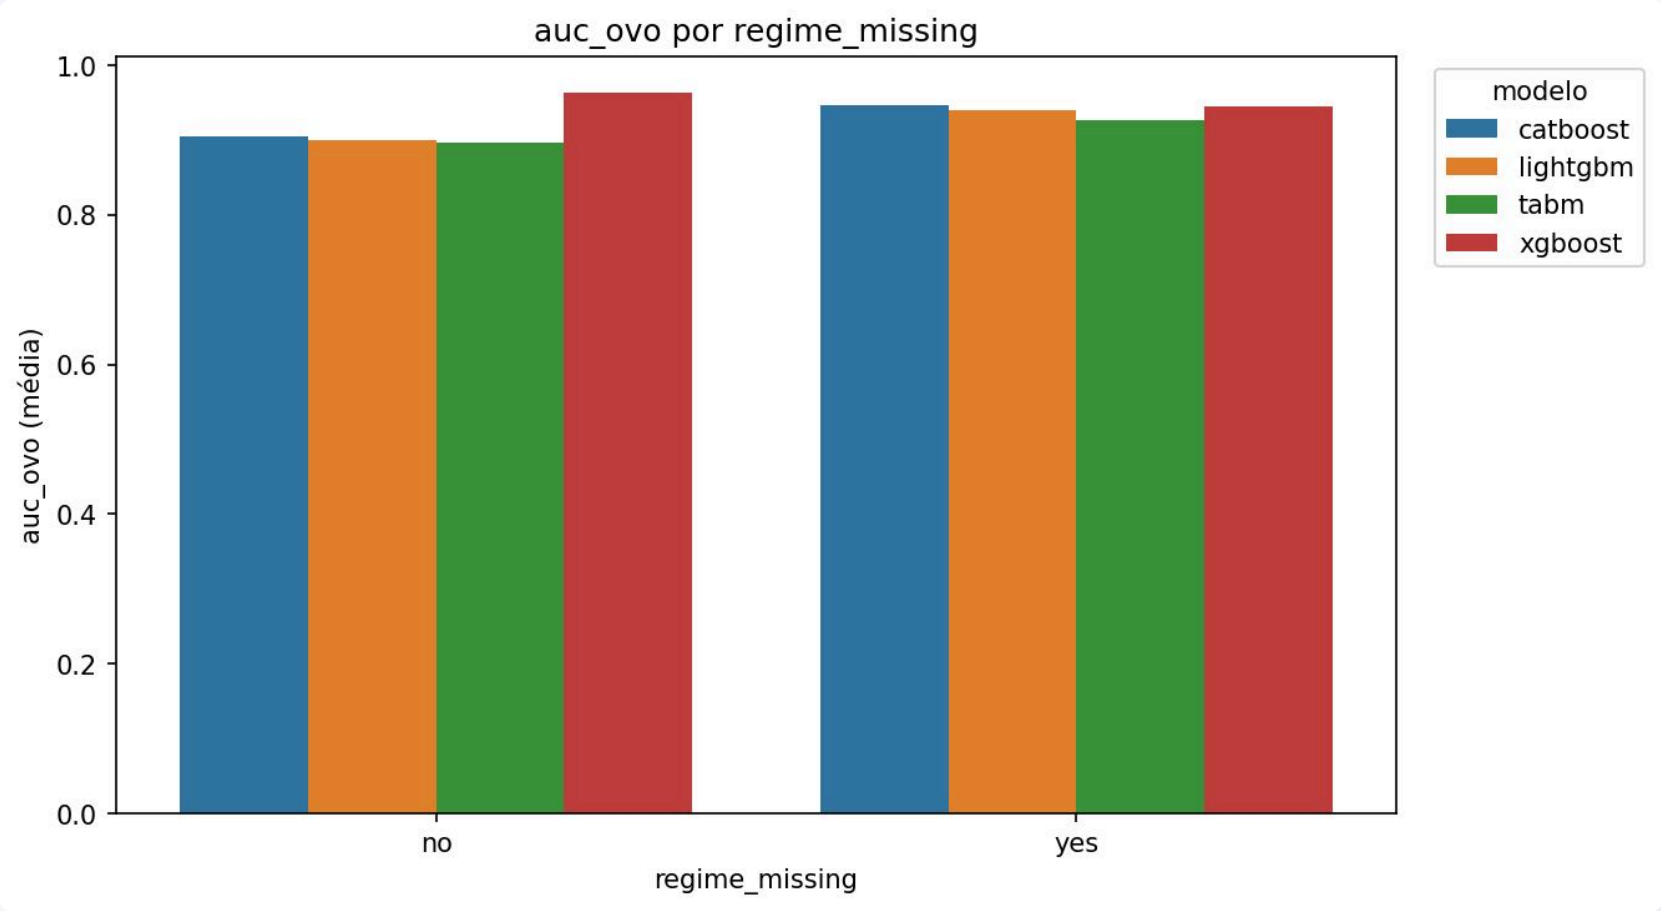
Made with GAMMA

Desempenho por Número de Classes (Teste)



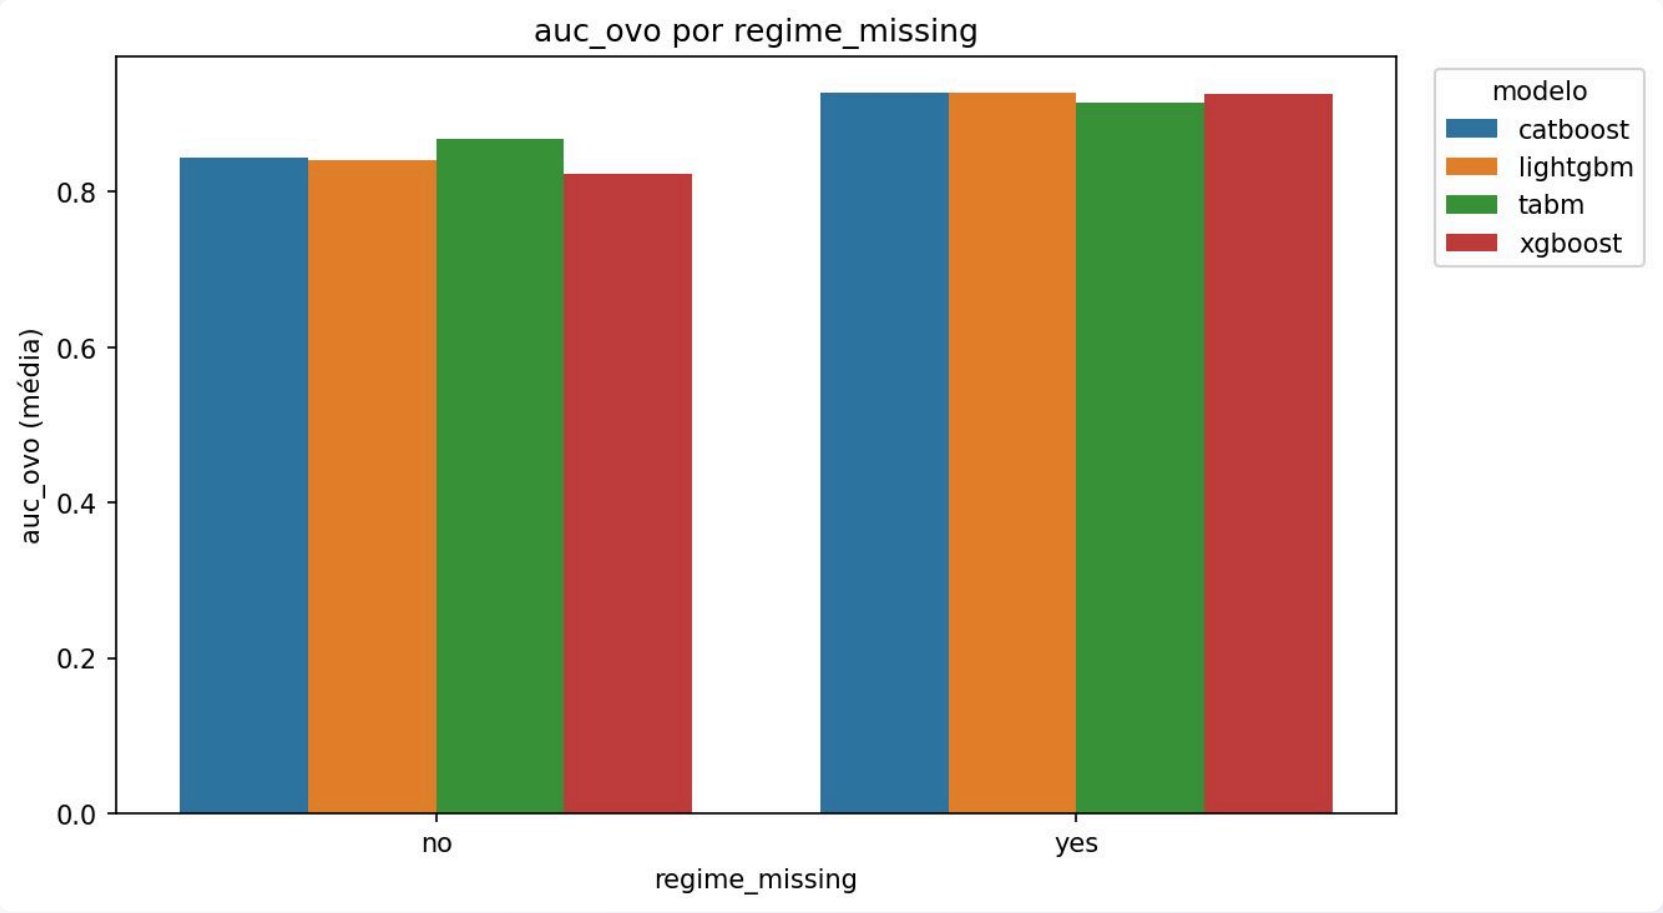
Made with GAMMA

Desempenho por Valores Faltantes (Treino)



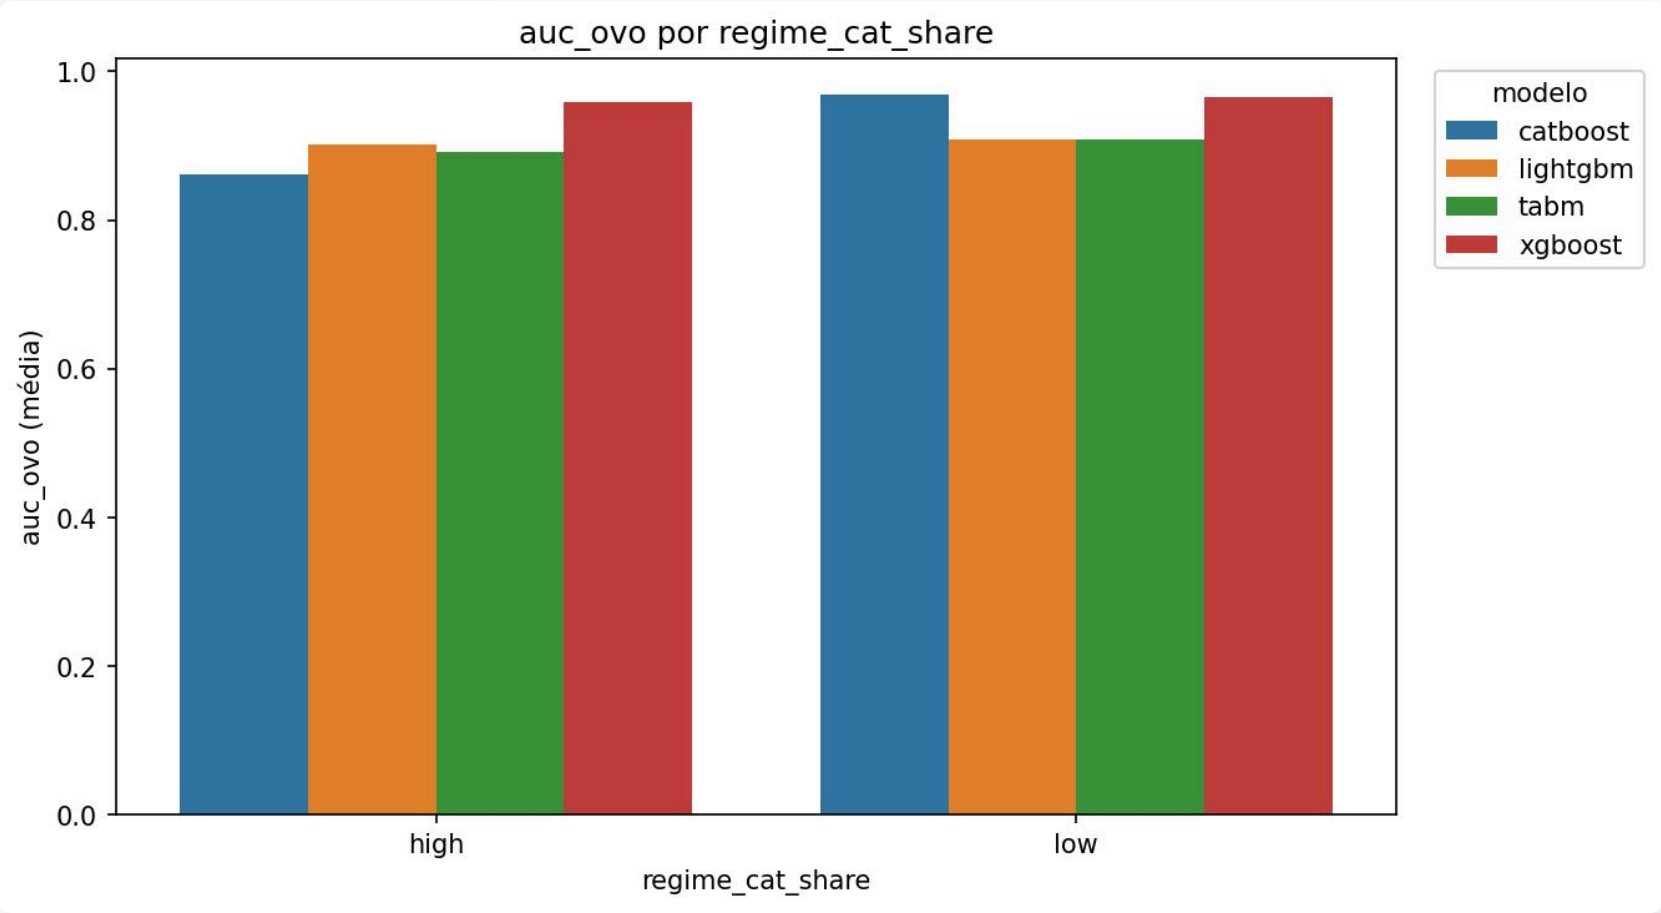
Made with GAMMA

Desempenho por Valores Faltantes (Teste)



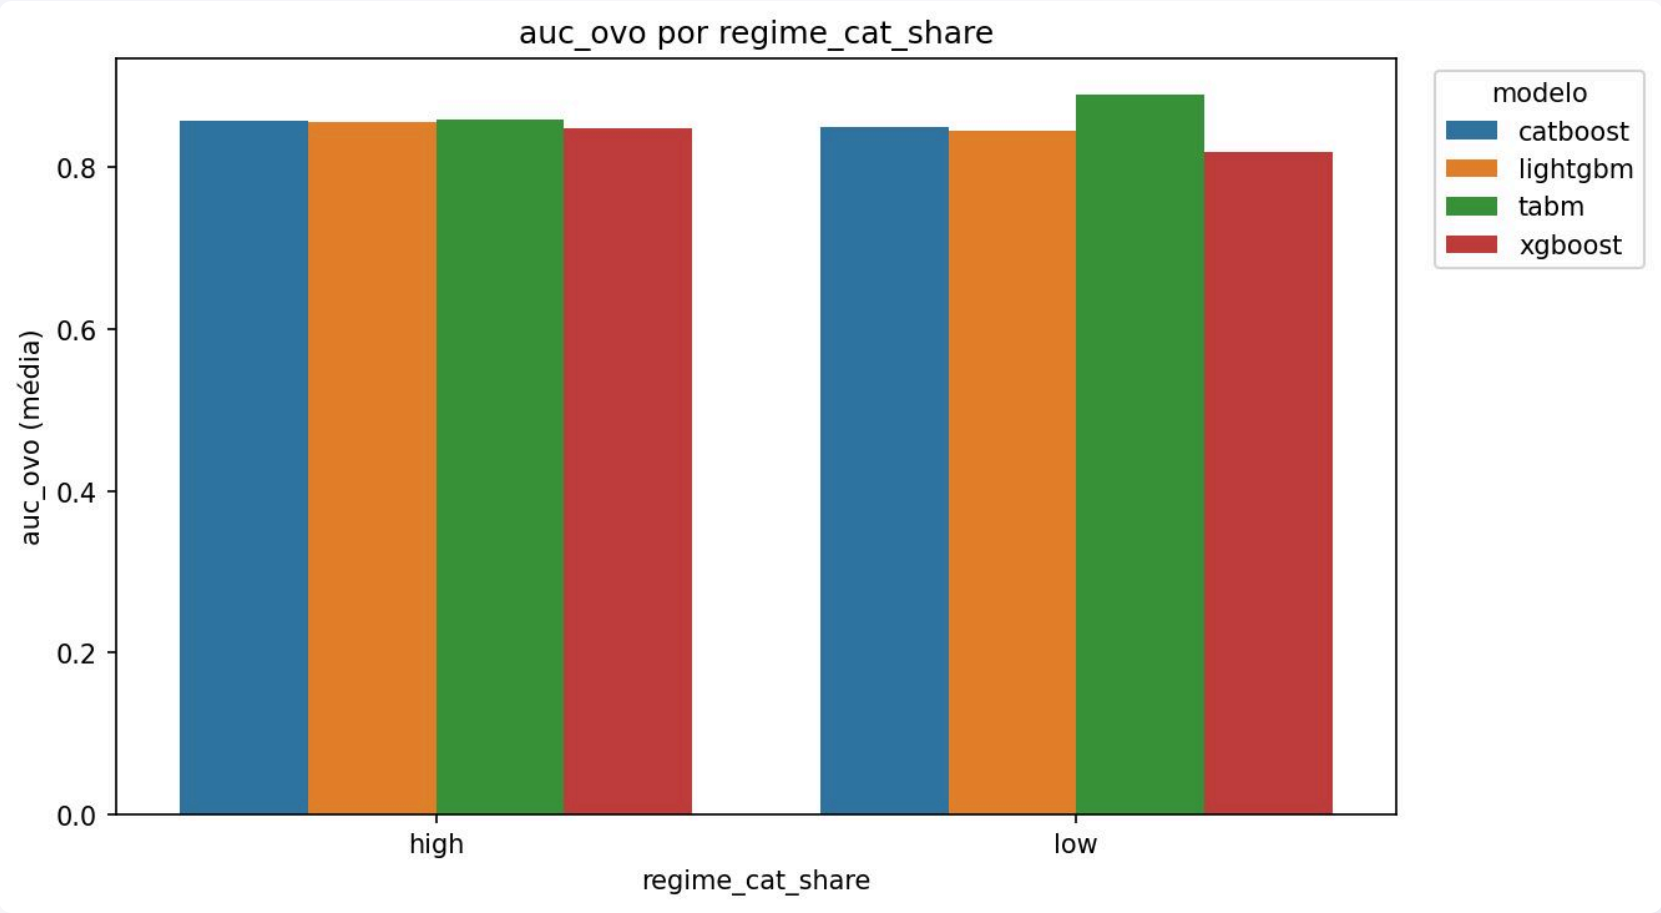
Made with GAMMA

Desempenho por Proporção de Variáveis Categóricas (Treino)



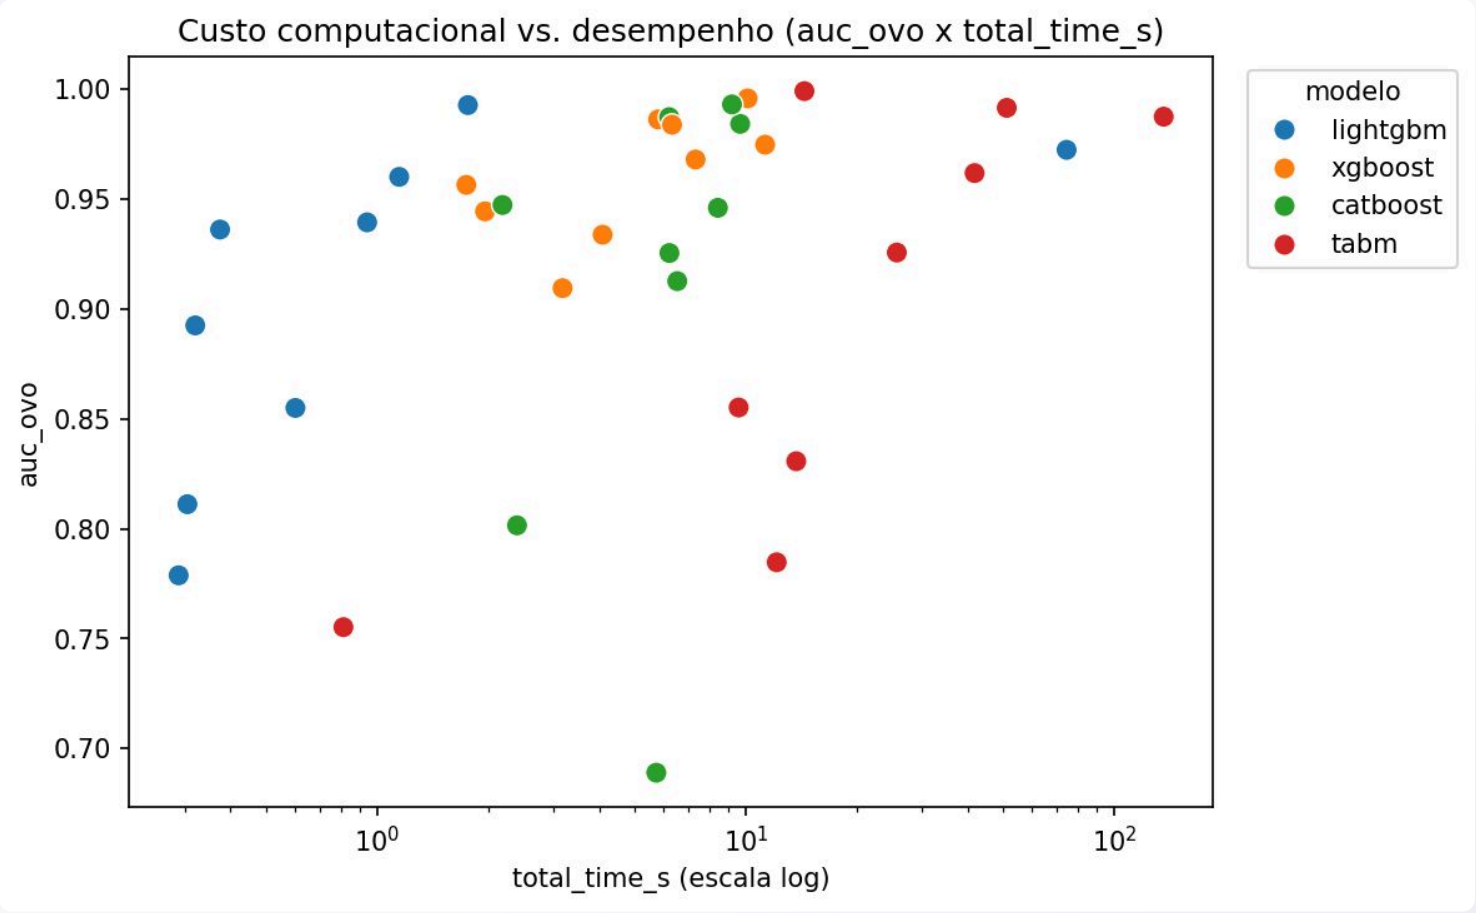
Made with GAMMA

Desempenho por Proporção de Variáveis Categóricas (Teste)



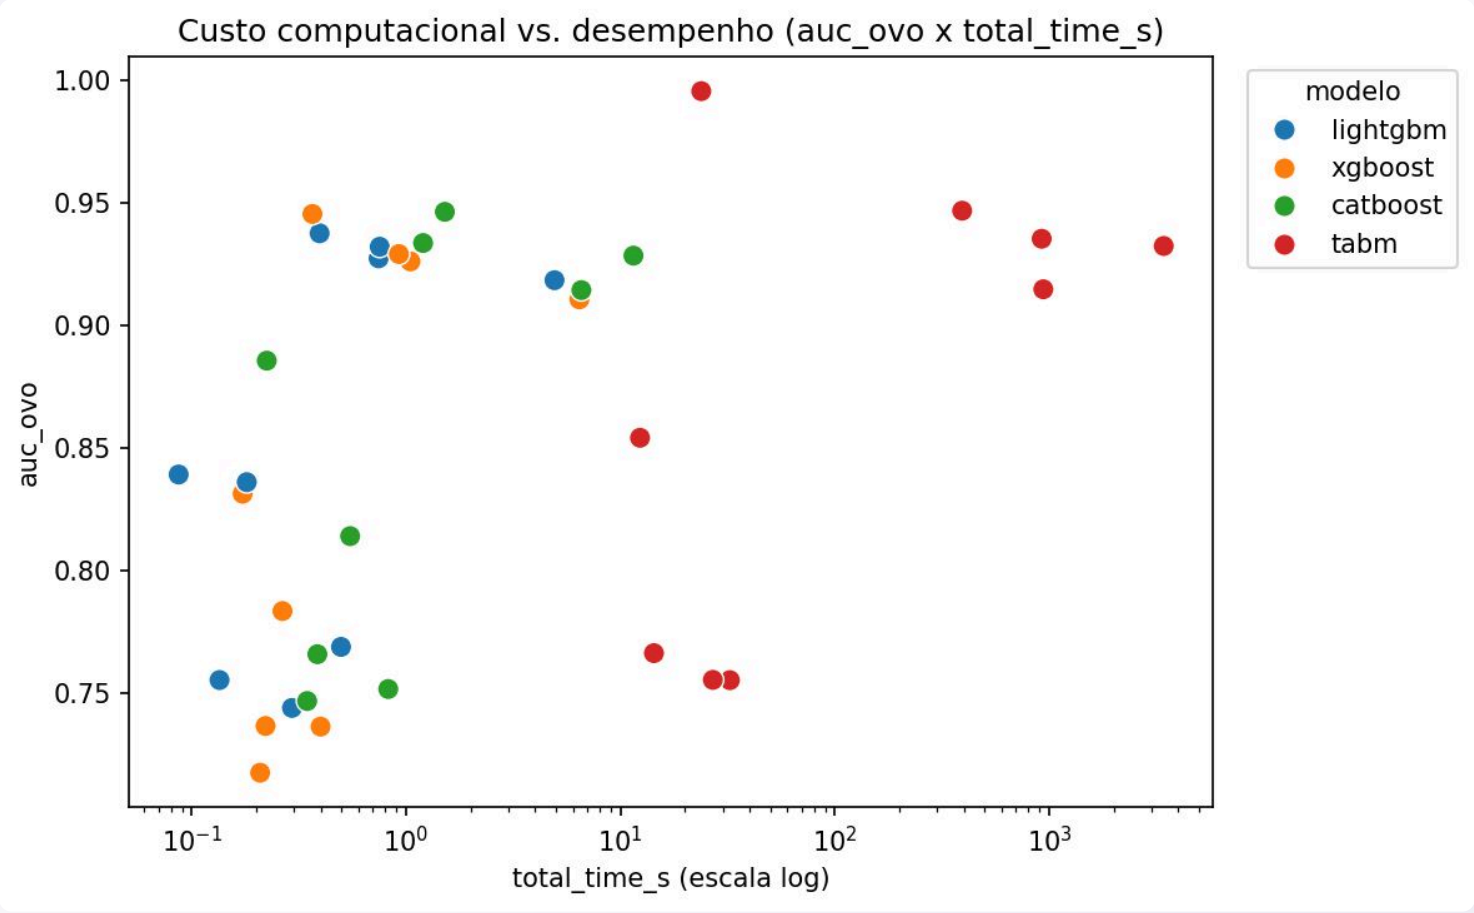
Made with GAMMA

Tempo x Qualidade (Treino)



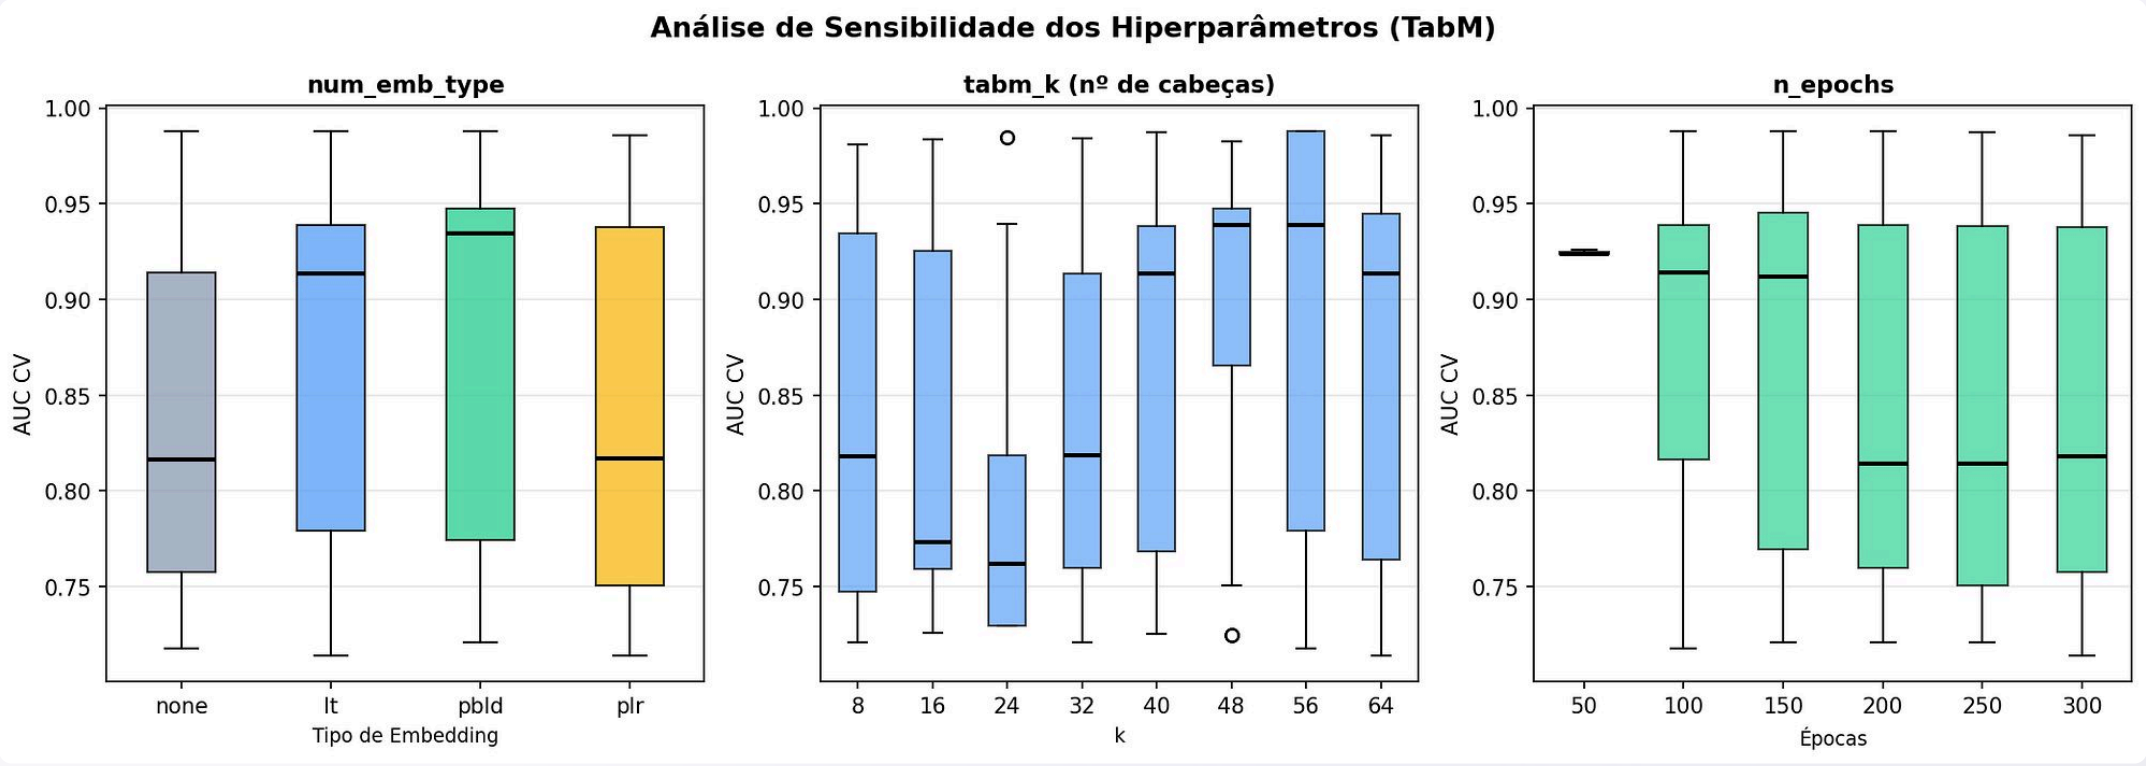
Made with GAMMA

Tempo x Qualidade (Teste)



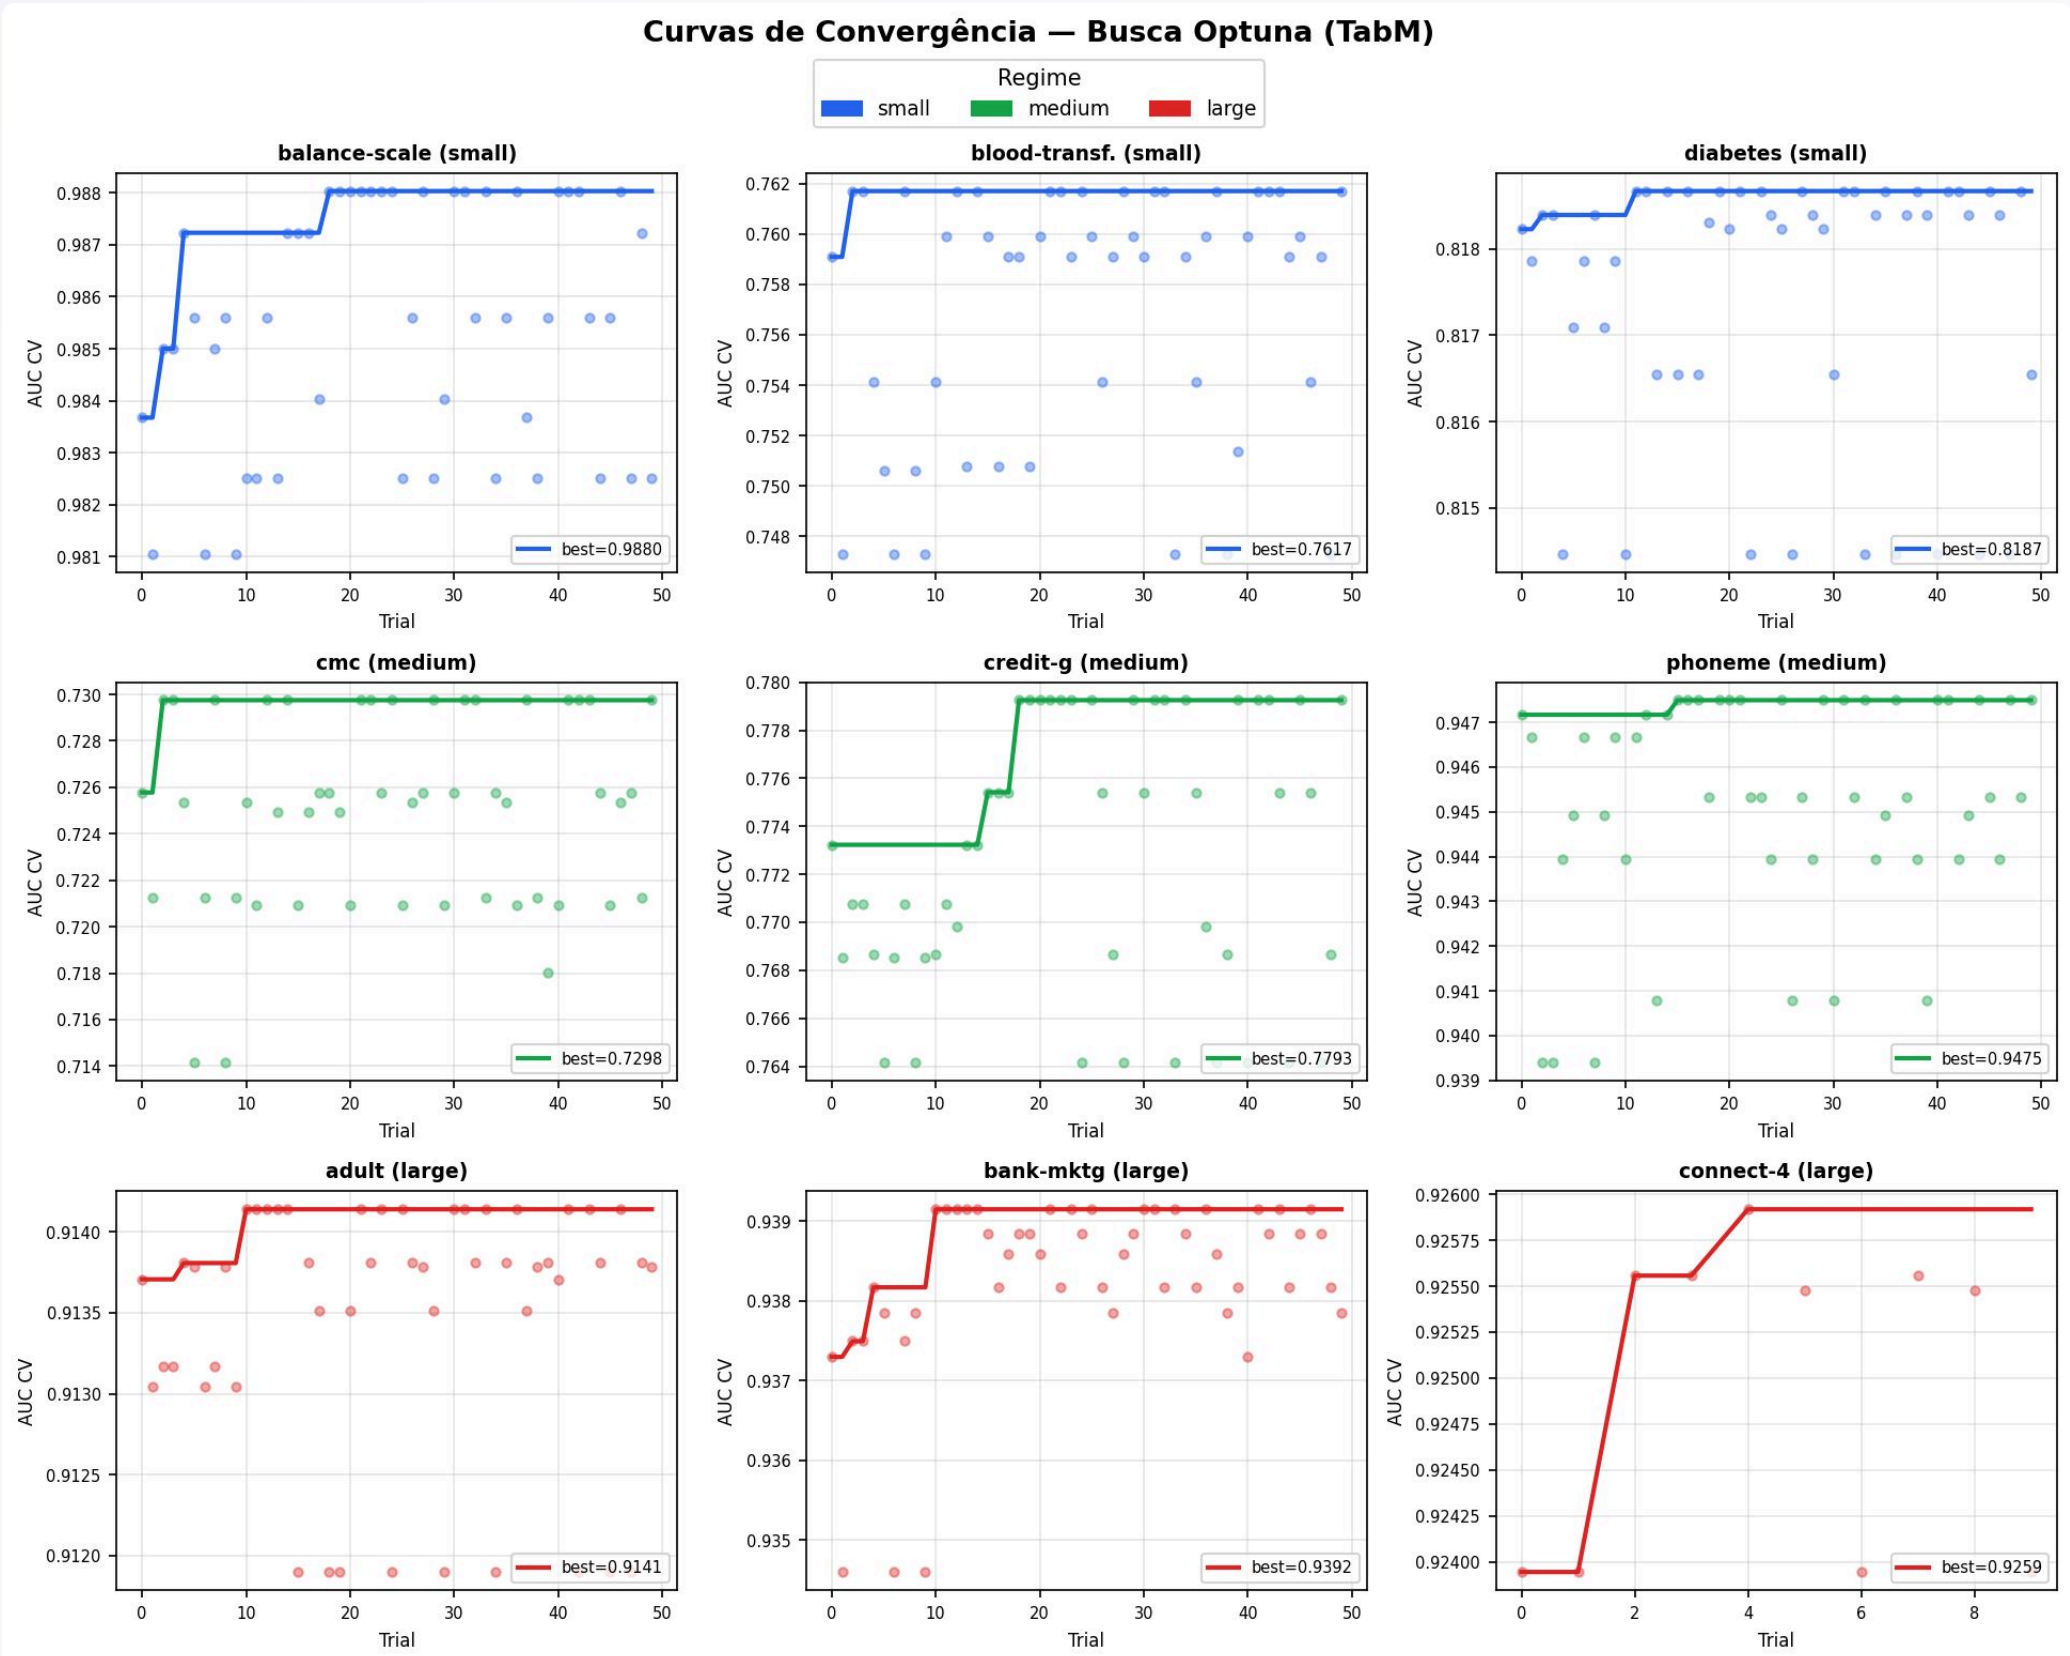
Made with GAMMA

Análise de Sensibilidade dos Hiperparâmetros



Made with GAMMA

Curvas de Convergência: Busca Optuna



Made with GAMMA

Resultados Gerais

Sistema	AUC	ACC	G-Mean	Tempo (s)
TabM	**0,873 ± 0,093**	**0,816 ± 0,119**	**0,694 ± 0,121**	**642,7**
LightGBM	0,851 ± 0,081	0,804 ± 0,109	0,580 ± 0,245	0,89
CatBoost	0,854 ± 0,084	0,805 ± 0,112	0,581 ± 0,244	2,57
XGBoost	0,835 ± 0,094	0,797 ± 0,112	0,580 ± 0,247	1,11

⚠ TabM: melhor AUC, ACC e G-Mean, porém **muito mais lento** que os demais.

Made with GAMMA

Conclusões

Posição

TabM **1º em AUC, ACC e G-Mean** entre os 4 modelos.

Ponto Forte

Multiclasse e regime small, pois ensemble implícito reduz variância.

Ponto Fraco

250× mais lento que CatBoost em CPU (642s vs 2,6s).

Quando Usar

Qualidade é prioridade, GPU disponível e regime small/medium.

Quando Não Usar

Latência restrita, datasets grandes sem GPU e interpretabilidade exigida.

Obrigado! Perguntas?

Repositório: **github.com/aanasc4/projeto-am**

Paper: Gorishniy et al. *TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling.* ICLR 2025 · **arxiv.org/abs/2410.24210**

Made with GAMMA